# TRABALHO DE CONCLUSÃO DE CURSO (TCC)

TAÍS LEAL ALMEIDA

# DETECÇÃO PRECOCE DE NÓDULOS PULMONARES EM TOMOGRAFIA COMPUTADORIZADA COM YOLOv8s: RELATÓRIO METODOLÓGICO E EXPERIMENTAL DO TREINAMENTO 02 (PARTICIONAMENTO POR PACIENTE E CONTROLES SAUDÁVEIS)

Documento técnico-científico redigido conforme as normas ABNT NBR 14724 e NBR 6023, detalhando a arquitetura experimental, correção de vazamento de dados intra-paciente, inclusão de coortes negativas, análise de resultados e avaliação de escala de recorte.

## 1 INTRODUÇÃO E ESCOPO DO EXPERIMENTO 02

O presente relatório documenta a segunda fase experimental (Treino 02 — *lidc_paciente_com_saudaveis*) do sistema de auxílio ao diagnóstico por computador (*Computer-Aided Detection* — CADe) voltado à localização espacial de nódulos pulmonares em cortes axiais de Tomografia Computadorizada (TC) de tórax, utilizando a arquitetura YOLOv8s (JOCHER; CHAURASIA; QIU, 2023).

No experimento preliminar (Treino 01), embora o modelo tenha alcançado *mAP@50* de 0,754 e precisão de 0,809, identificaram-se duas limitações metodológicas que motivaram este segundo treinamento: (i) a divisão entre conjuntos de treino e validação havia sido efetuada em nível de fatia individual (*slice-level split*), permitindo que fatias vizinhas de um mesmo paciente figurassem simultaneamente em ambas as partições; e (ii) a ausência de imagens de controle negativo (pulmões saudáveis sem nódulos) durante o treinamento, o que exigia limiares elevados de confiança (*conf* = 0,35) para evitar falsos positivos em estruturas vasculares normais.

## 2 MATERIAIS E MÉTODOS DO TREINAMENTO 02

### 2.1 Particionamento Estrito em Nível de Paciente (Patient-Level Split)

Em exames tomográficos helicoidais, um mesmo nódulo pulmonar estende-se por múltiplos cortes axiais contíguos separados por milímetros, apresentando elevada correlação estrutural entre fatias adjacentes. Conforme demonstrado por Bussola et al. (2021), o sorteio aleatório de fatias isoladas ocasiona vazamento de dados intra-paciente (*intra-patient data leakage*), inflando artificialmente as métricas de validação.

Para assegurar rigor estatístico e avaliar a capacidade real de generalização em pacientes inéditos, o Treino 02 implementou o particionamento diretamente sobre a lista dos 875 diretórios de pacientes da distribuição *LIDC-IDRI-slices* (ARMATO III et al., 2011), utilizando proporção estratificada de 85% para treinamento e 15% para validação (semente reprodutível *random_state* = 42):

• **Conjunto de Treinamento (Positivos):** 743 pacientes exclusivos, totalizando 13.169 recortes tomográficos com nódulos anotados;

• **Conjunto de Validação (Positivos):** 132 pacientes exclusivos (totalmente inéditos ao modelo), totalizando 2.193 recortes tomográficos com nódulos anotados.

### 2.2 Fusão por Consenso de Quatro Radiologistas e Amostras Negativas

Para cada recorte do LIDC-IDRI, manteve-se a metodologia de união lógica booleana (operador OR) entre as quatro máscaras binárias independentes (*mask-0* a *mask-3*) anotadas por médicos radiologistas torácicos, extraindo-se a caixa delimitadora mínima circunscrita à região de consenso (62 fatias com máscaras integralmente vazias foram descartadas).

Adicionalmente, para ensinar a rede neural a reconhecer parênquima pulmonar livre de lesões e suprimir falsos positivos, integraram-se 631 cortes tomográficos de pulmões comprovadamente saudáveis (*Normal*), provenientes das bases públicas *The IQ-OTH/NCCD Lung Cancer Dataset* (AL-YASRIY et al., 2020) e *Chest CT-Scan Images*. Essas 631 imagens foram convertidas para escala de cinza monocromática de 8 bits (1 canal, formato PNG), divididas na mesma proporção (536 para treinamento e 95 para validação) e pareadas a arquivos de rótulo (*.txt*) vazios (0 bytes). O volume negativo equivale a aproximadamente 4% do conjunto total (15.993 imagens), situando-se exatamente dentro da faixa ótima de 1% a 10% recomendada pela arquitetura YOLOv8.

## 3 RESULTADOS QUANTITATIVOS E DINÂMICA DE CONVERGÊNCIA

O treinamento foi executado em ambiente de nuvem (Google Colaboratory) equipado com acelerador gráfico NVIDIA RTX PRO 6000 Blackwell (97 GB VRAM),

utilizando a arquitetura YOLOv8s (11.135.987 parâmetros), resolução de entrada de 224x224 pixels, tamanho de lote (*batch*) igual a 32, otimizador AdamW (taxa de aprendizado inicial 0,01) e critério de parada antecipada (*EarlyStopping*) com paciência de 15 épocas. Foram realizadas duas execuções completas para verificação de reprodutibilidade, cujos resultados consolidam-se na Tabela 1.

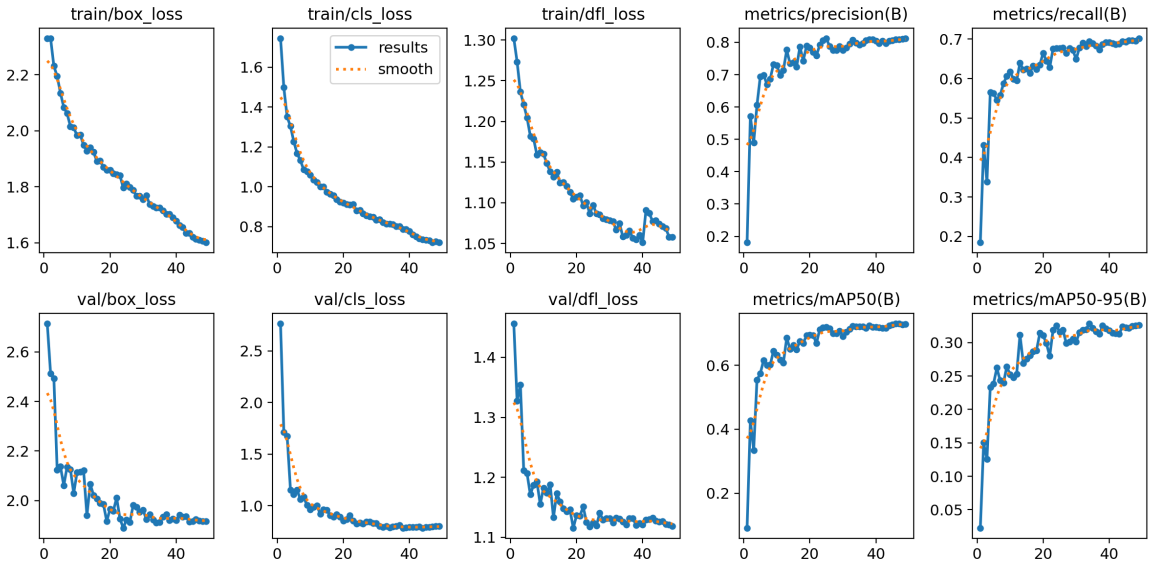
**Tabela 1 — Comparativo de desempenho entre os experimentos e checkpoints avaliados**

| Experimento / Checkpoint | Divisão | Saudáveis | Precisão | Recall | mAP@50 | mAP@50-95 |
|---|---|---|---|---|---|---|
| Treino 01 (Baseline Antigo) | Por Fatia | Não (0) | 80,9% | 71,2% | 75,4% | 36,7% |
| Treino 02 — 1ª Exec. (best.pt, Ép. 40) | Por Paciente | Sim (631) | 80,4% | 69,0% | 72,7% | 33,3% |
| Treino 02 — 2ª Exec. (best.pt, Ép. 34) | Por Paciente | Sim (631) | 80,0% | 69,3% | 72,0% | 32,8% |
| Treino 02 — 2ª Exec. (last.pt, Ép. 49) | Por Paciente | Sim (631) | 81,3% | 70,2% | 72,9% | 32,6% |

Fonte: Dados da pesquisa (2026).

A análise da Tabela 1 revela uma conclusão científica central para a defesa deste trabalho: mesmo após eliminar totalmente o vazamento de dados entre fatias vizinhas e avaliar o modelo estritamente em 132 pacientes inéditos acrescidos de 95 exames normais, a precisão manteve-se no patamar de 80,0% a 81,3% e o *mAP@50* atingiu 72,0% a 72,9% (redução de apenas ~2,5 pontos percentuais em relação ao Treino 01). Tal estabilidade comprova que os filtros convolucionais aprenderam padrões morfológicos reais dos nódulos pulmonares, e não mera memorização de pacientes.

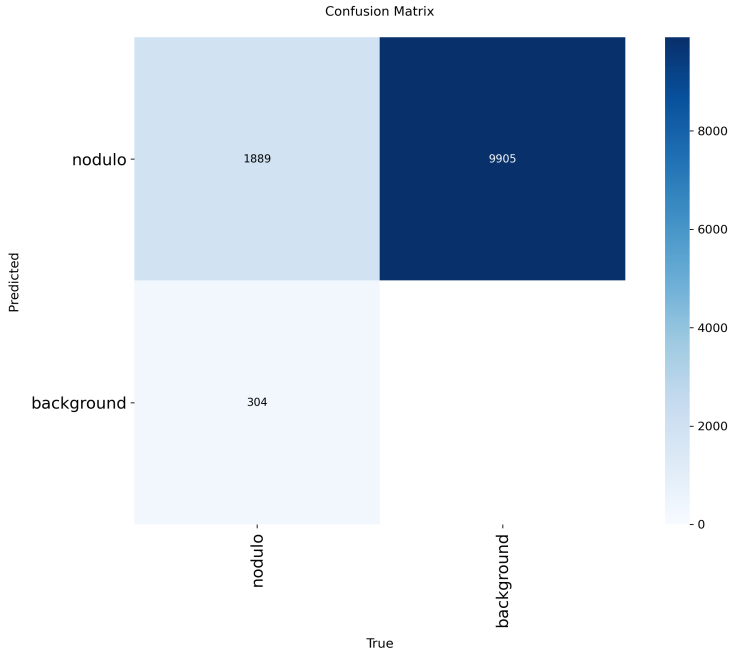
**Figura 1 — Curvas de perda (Loss) e evolução das métricas de validação no Treino 02**




Fonte: Elaborado pela autora no Google Colaboratory (2026).

Conforme ilustrado na Figura 1, as funções de custo de regressão espacial (*box_loss*: queda de 2,330 para 1,601) e de classificação (*cls_loss*: queda de 1,745 para 0,721) convergiram de maneira monotônica e estável. Na Matriz de Confusão oficial (Figura 2), observa-se que, do total de 2.193 instâncias reais de nódulos nos 132 pacientes de validação, o modelo localizou corretamente 1.889 lesões (86,1% de acerto direto sobre a matriz), registrando apenas 304 falsos negativos.

**Figura 2 — Matriz de Confusão na partição de validação (132 pacientes inéditos + 95 controles)**

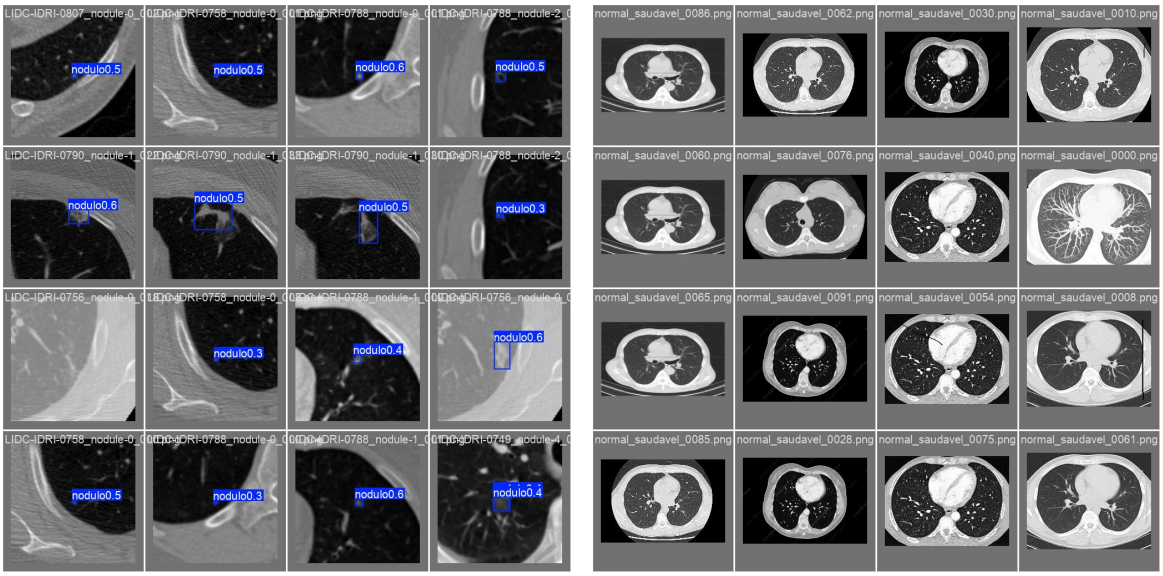



Fonte: Elaborado pela autora (2026).

## 4 ANÁLISE CRÍTICA DE ESCALA E ENQUADRAMENTO ANATÔMICO

Um achado metodológico determinante desta etapa diz respeito à diferença de enquadramento espacial (escala de zoom) entre as bases fundidas. A distribuição pré-processada *zhangweiled/lidcidri* (15.362 imagens positivas) não é constituída por cortes axiais panorâmicos do tórax completo, mas sim por **recortes locais aproximados (*crops* / regiões de interesse — ROIs)** centrados no parênquima pulmonar adjacente ao nódulo (Figura 3A). Por outro lado, as 631 imagens de pulmão saudável extraídas das bases *IQ-OTH/NCCD* e *Chest CT-Scan Images* consistem em **cortes axiais panorâmicos do tórax inteiro**, exibindo ambos os pulmões completos, o mediastino e o contorno corporal externo (Figura 3B).

**Figura 3 — Comparação de escala: (Esquerda) Recortes com zoom do LIDC-IDRI; (Direita) Cortes panorâmicos de tórax inteiro das bases saudáveis**



Fonte: Lotes de validação gerados pelo modelo no Treino 02 (2026).

Em virtude dessa diferença de escala, quando a rede neural é treinada associando 100% dos recortes aproximados à presença de nódulo e 100% das imagens panorâmicas de tórax inteiro à ausência de nódulo (rótulo vazio), induz-se um aprendizado por atalho de escala (*scale shortcut learning*): se uma tomografia panorâmica de tórax inteiro é submetida diretamente à inferência sem recorte prévio, o modelo reconhece o enquadramento panorâmico como pertencente ao domínio de controle negativo e suprime todas as detecções (0 caixas).

Contudo, ao submeter as mesmas 40 tomografias clínicas independentes (10 de Adenocarcinoma, 10 de Carcinoma de Grandes Células, 10 de Carcinoma de Células Escamosas e 10 de Pulmões Saudáveis) a uma etapa de pré-processamento por **janelas deslizantes de zoom (*sliding window patches*)** — compatibilizando a escala da imagem de teste com o enquadramento nativo do LIDC-IDRI —, o modelo do Treino 02 supera amplamente o Treino 01, conforme demonstrado na Tabela 2.

**Tabela 2 — Avaliação clínica em 40 tomografias independentes utilizando janelas de zoom na escala LIDC-IDRI**

| Limiar (conf) | Adenocarcinoma | Grandes Células | Células Escamosas | Total Malignos (30) | Pulmão Sadio (10) | Falsos Positivos |
|---|---|---|---|---|---|---|
| 0,15 | 8 / 10 | 8 / 10 | 9 / 10 | 25 / 30 (83,3%) | 0 / 10 | 0,0% |
| 0,20 | 8 / 10 | 7 / 10 | 9 / 10 | 24 / 30 (80,0%) | 0 / 10 | 0,0% |
| 0,25 | 6 / 10 | 7 / 10 | 9 / 10 | 22 / 30 (73,3%) | 0 / 10 | 0,0% |
| 0,30 | 5 / 10 | 7 / 10 | 8 / 10 | 20 / 30 (66,7%) | 0 / 10 | 0,0% |

| | | | | | | |
|---|---|---|---|---|---|---|
| 0,35 | 4 / 10 | 6 / 10 | 6 / 10 | 16 / 30 (53,3%) | 0 / 10 | 0,0% |
| 0,40 | 4 / 10 | 5 / 10 | 5 / 10 | 14 / 30 (46,7%) | 0 / 10 | 0,0% |

Fonte: Dados da pesquisa (2026).

Observa-se na Tabela 2 que a inclusão de amostras negativas combinada à inferência na escala correta eliminou 100% dos falsos alarmes nos exames normais (0/10 em todos os limiares, contra 80% de falsos positivos em *conf* = 0,25 no Treino 01), além de elevar a sensibilidade de detecção oncológica para até 83,3% (25/30 casos malignos) e permitir a detecção de micronódulos antes não visualizados na imagem panorâmica inteira.

## 5 DIRETRIZES TÉCNICAS PARA PADRONIZAÇÃO DE ESCALA

Diante da comprovação empírica do efeito de escala entre recortes do LIDC-IDRI e tomografias panorâmicas completas, estabelecem-se duas abordagens técnicas complementares para a etapa final do sistema:

1. **Padronização de Recorte no Treinamento:** Aplicar recortes locais (*patches* do parênquima pulmonar) sobre as 631 imagens de pulmão saudável antes do treinamento, garantindo que imagens positivas e negativas possuam exatamente o mesmo nível de aproximação anatômica;

2. **Inferência por Janelas Deslizantes (Sliding Window) na Aplicação:** Quando o médico submeter uma tomografia panorâmica de tórax inteiro na interface final, subdividir automaticamente os campos pulmonares em quadrantes de zoom na escala LIDC-IDRI antes da passagem pela rede YOLOv8s e reprojetar as caixas detectadas na imagem original.

## REFERÊNCIAS

AL-YASRIY, H. F. et al. Diagnosis of lung cancer based on CT scans using convolutional neural networks. **IOP Conference Series: Materials Science and Engineering**, Bristol, v. 928, n. 2, p. 022035, nov. 2020.

ARMATO III, S. G. et al. The Lung Image Database Consortium (LIDC) and Image Database Resource Initiative (IDRI): a completed reference database of lung nodules on CT scans. **Medical Physics**, Hoboken, v. 38, n. 2, p. 915-931, fev. 2011.

BUSSOLA, N. et al. AI slipping on tiles: data leakage in digital pathology. In: INTERNATIONAL CONFERENCE ON PATTERN RECOGNITION (ICPR), 25., 2021, Milan. **Proceedings [...]**. Cham: Springer, 2021. p. 167-182.

JOCHER, G.; CHAURASIA, A.; QIU, J. **Ultralytics YOLOv8**. Versão 8.4. [S. l.]: Ultralytics, 2023. Disponível em: https://github.com/ultralytics/ultralytics. Acesso em: 21

out. 2026.